研究进展汇报｜心理学启发的 LLM 长期记忆检索与保留

截至2026年10月13日 · 组会汇报材料 · 初步探索，不作为方法有效性的最终证明

研究问题

在长期聊天历史中，系统既要找到当前需要的经历，也要在有限预算下保留未来可能需要的信息。本研究围绕两个问题展开：情绪与交流目的能否提供语义之外的提取线索？历史使用与主动提取练习能否改善后续记忆使用，并避免更新干扰？

目前完成的三条主线

主线	主要工作	当前判断
情绪与评价信息	CPM标注、情绪融合、配额、AIM原型、目的条件选择	部分局部信号存在，尚无稳定整体检索增益
提取练习与更新	保留模拟、跨问题迁移、回忆写入、DeepSeek练习、竞争抑制	保留机制有潜力；练习优于重读尚未证实
预算下的记忆保留	WorkBuddy在线保留、粒度与污染探索	历史标准证据反馈有收益，部署信号及基线仍需核查

数据与实验范围

材料	范围	用途与边界
LoCoMo原项目	100查询、2,531记忆；补全10对话、5,882话轮	CPM、检索、状态干预及部分记忆更新
分享记录中的LoCoMo子集	前2对话、788话语；230可评价官方题	BGE/RRF、情绪诊断、DeepSeek；不与全项目混算
LongMemEval	200官方题扩展；60题竞争更新子集；18组跨题配对	分别评价，不能合并成一个样本量
其他材料	EmpatheticDialogues512情境；CMI；MINTEval	情绪类别诊断及相关研究部分复现

多方法、状态、模板和随机种子产生的重复记录，不等于新增独立用户或问题。整体仍以探索性研究定位。

一、情绪与 CPM：从标注到检索对照

已完成的工作

恢复已有数据，核对原文人物、事件、时间及摘要冲突；区分真人审核、AI暂定标注和官方证据代理。根据SEC心理学定义表建立有版本的14维编码，并完成100条训练记忆语义试标与一位真人的1,400个CPM审核单元。

真人审核中835个单元有取值，827个能匹配局部引文。目标相关性、目标促进／阻碍可作为证据型探索特征；其他部分维度存在定义混淆或覆盖不足。没有第二位审核者，尚不报告量表效度或人工一致性。

检索与干扰实验

实验	结果	解释
BM25／TF-IDF／Dense及Emotion、CPM融合	开发集选择附加权重均为0；32个有效测试查询Dense Recall@5=77.5%	未观察到额外收益；规则CPM稀疏、标签不完整
30条自然具体问题×2当前状态	证据Hit@5：66.7%→拼接状态61.7%→加情绪名额56.7%	状态干预可能扰动事实检索；不是普遍定律
LongMemEval200官方问题	加情绪后Hit@5仍97%；证据Recall@5由95.3%至94.3%	随机辅助分数也有损失，不能归因于情绪特有噪声
AIM启发连续权重	小测试nDCG@3：0.524→0.535；改写后增益不稳定	关键词意图识别失败；未验证AIM四策略
情绪×目的规则原型	210候选记忆、240条件、1,680排序；行动组联合与只给目的前5相同	实现已运行，但未观察到行动组情绪额外选择作用

WorkBuddy情绪探索的归纳

上传脚本覆盖加权、门控、取层与存层配额、自适应配额、情绪强度／心情一致性、弱语义补位及多信号对照。多数实现未取得稳定整体收益，但不能写成“十种方法证明情绪无用”。

严格证据日志存在中间最优：0.212／0.514／0.590／0.628／0.623／0.524；最佳0.628仍低于纯语义0.650。因此“存在最佳配比”与“超过基线”是两个问题。情绪题比例约8%也不能自动构成整体收益上界。

阶段结论：情绪与评价信息不等于无信息，但在现有事实问答、表示和预算下尚未形成稳定增益。情绪相似性与当前交流帮助性需要分开评估。

二、新增分享记录：REALM 启发的情绪线索与真实提取练习

本页依据公开分享记录整理，未取得该分支的全部原始代码、API日志及复评分产物，数字保留为记录报告值。

研究设想与实现

分享记录以 REALM（Retrieval-Driven Memory Reconsolidation for Long-Term LLM Agents）为参考，探索主动练习与情绪线索。基础论文的描述来自该分享记录，本轮未重新核验全文；未复现完整REALM系统，也未直接与MAGMA、Zep、Mem0、A-Mem、Nemori、MIRIX比较。

每条话语携带同会话此前最多两句话。使用TF-IDF、BGE-small英文嵌入、RRF混合检索，以及情绪标签匹配和标签打乱对照。第一轮及第二轮分别构造12道情绪诊断题，第二轮减少事件关键词；题目由看过原文的方法设计者编写，属于诊断而非独立盲测。

阶段	记录中的结果
TF-IDF＋情绪	12道自编题首条证据命中3/12→11/12；前10证据覆盖及230官方题召回未改善
BGE／RRF＋情绪	相对纯语义，12题中6题增加覆盖、1题减少；相对更强混合检索，1题增加、1题减少
离线练习，5组安排	反馈练习相对更新强度匹配重读，官方证据覆盖平均仅+0.13个百分点；情绪题相同
DeepSeek流程试跑	2次练习、3道测试；三组结果相同，验证流程可执行

DeepSeek扩大实验：16次练习、30道测试

三组分别为不更新、直接重读生成笔记、先检索回答再读原文纠错生成笔记；重读与练习使用同样原文和笔记生成规则，试图区分主动尝试提取与重新整理信息。

组别	原始自动判对	前5证据覆盖	前10证据覆盖
不更新	15/30（50.00%）	72.78%	74.44%
直接重读	14/30（46.67%）	66.11%	74.44%
提取练习	16/30（53.33%）	66.11%	74.44%

重要限制：裁判漏用日期信息，存在时间题误判；练习比重读多对的两题中有一题受其影响，尚未收到修复后的评分。新增笔记也可能挤掉关键原始证据。因此不能把16/30与14/30的差距作为练习有效的证明。

新问题：如何同时找回情绪描述与事件背景？练习后的纠错是否能形成比直接重读更有用的关联？

三、提取练习与竞争抑制：已运行的机制实验

保留模拟与跨问题迁移

实验	主要数字	结论边界
LongMemEval200题保留模拟，25%容量	证据Recall@5：不更新25.8%、刷新49.7%、检索强化63.1%、随机强化26.0%	强化后的保留优势由机制规定；不是认知效应证明
18组早／晚不同问题，25%容量	不更新24.5%、刷新38.0%、强化46.6%、随机24.4%	支持共享证据子集的保留迁移，非全数据代表
FLAN-T5-small真实生成，18组	答案token F1：不练习0.232、复制0.321、摘要0.205、回忆QA0.261	主动回忆未稳定超过直接复制；非人工回答准确率

未来任务副作用与候选恢复

运行公开Lethe的原始RIF更新核心，使用真实MiniLM、BM25、RRF和交叉编码器。LongMemEval60问、28,751话轮；5个练习／未来划分、不同练习次数。该实验是工程机制扩展，不是完整生产系统复现或经典心理学RIF证明。

设置	未来nDCG@10	相对不更新
不更新	0.5096	—
原始竞争抑制	0.4655	−0.0441
排名落差保护	0.4901	−0.0194
查询分组	0.4911	−0.0185

原公式5个划分中4个下降、1个上升，损害涉及11个不同问题。候选30／40／50时损害只能部分恢复；将全部原始检索候选并集交给重排后，两组均为0.5016。该相等由集合和重排相同保证，定位了候选截断环节，并非学习到新保护机制。

情绪×练习交叉

17组、6段对话：未来事实Recall@5从纯语义冻结55.29%，至情绪冻结49.41%，再至情绪练习20次47.94%。静态损失5.88个百分点，练习额外损失1.47个百分点且不确定区间含0。未支持情绪额外放大整体损害；无情绪任务隔离也能保护跨任务检索。

阶段结论：历史更新既可能有保留价值，也可能误伤未来证据。应分开分析“加入辅助分数”“改变保留集合”“抑制候选”“改写记忆”四类作用。

四、WorkBuddy 存储主线：在线保留与污染压力测试

研究转向

从静态情绪排序转向“有限预算下，历史使用是否能指导保留”。探索使用频次、衰减、多样性、记忆粒度和冗余污染。当前更接近保留／缓存适应问题；心理学提取练习是启发，尚非机制已被验证。

旧上传日志中可核对的结果

粒度／保留预算	最强已列静态基线	在线避重方法	差值
摘要／25%	0.369	0.428	+0.059
摘要／50%	0.502	0.580	+0.078
话轮／25%	长度0.393	0.433	+0.040
话轮／50%	长度0.467	0.451	−0.016

不能写“四档全部优于最强静态基线”。与多样性比较的显著性不能转用于长度基线；旧统计还需按问题来源及完整对话重新核算。

在线设置的关键解释

旧脚本先评价、后更新，但更新直接给当前题的官方证据加分，包含没被检索出来的证据。这是历史标准证据反馈，不是系统自动判断记忆被实际使用。底层完整池仍存在，活跃集合可重新选入记忆；所谓“永久丢失”实际是当前证据缺失，应区别总存储删除与有限缓存。

最新污染汇总：待核查的新结果

污染比例	基线	方法	差值
0%	0.399	0.452	+0.053
50%	0.329	0.508	+0.179
100%	0.274	0.517	+0.243

以上来自用户最新WorkBuddy汇总，尚未核对对应新脚本。需要确认：近义重复是否也算有效证据；答案证据计分是否天然排除了污染项；污染增加时预算固定的是绝对容量还是比例。在这些检查前，“越脏越强”作为待验证发现，不能作为已确证优势。

其他新汇总包括使用频次预测约0.65 – 0.70、情绪约0.52、加工深度粒度效应等；预测指标、变量操作和数据划分尚需绑定来源。长度不等同于加工深度，年龄关联不等同于普遍记忆规律。

五、可信性检查、当前结论与下一步

相关研究与评测检查

CMI部分复现：官方BM25在有效更新条件的证据Hit@3由低负载100%降至高负载28%；模板规则可解决该受控子协议，需避免把模板识别解释为自然记忆理解。未复现其完整Dense、生成或训练流程。

MINTEval评分检查：1000个构造负数计数错误仍被判EM正确；435个倒序答案词袋F1满分但EM为0。已实现类型化防护。这是评分器反例，不估计论文成绩被抬高多少。

旧情绪脚本5处Holm实现修复；重算372项旧日志检验，标记改变0项。修复不等于全部检索重跑，仍须处理对话相关性和同数据选优。

目前可以支持的三点

① 情绪信号具有局部信息，但现有事实问答和简单融合未显示稳定整体收益。② 历史反馈可改变保留与检索；其收益依赖反馈质量、预算和粒度，真实部署价值仍待确认。③ 更新可能产生未来任务副作用，冗余与竞争应与收益共同评价。

目前尚不支持的表述

不宣称情绪普遍无用、提取练习效应已经成立、存储评测完全空白、所有预算均显著胜出或方法具备主会竞争力。访问频次必须与LFU/LRU等缓存策略比较；心理学命名本身不构成技术创新。

下一阶段优先级

优先级	实验	判定目标
1	复核DeepSeek时间评分及新增笔记证据忠实性	确认表面差距是否仍存在
2	标准证据反馈／实际访问／可追溯回答使用三组保留对照；补长度、LFU/LRU、去重	分离理想反馈与可部署机制
3	情绪弱线索、事件相近的独立诊断；情绪＋事件背景联合召回	情绪是否超越强混合检索
4	更强模型的练习／重读，匹配原文、写入与上下文预算；测试新问题迁移	尝试提取是否具有额外价值
5	第二数据、自然重复及固定预算污染；按对话聚类统计	验证边界与泛化，而非只增加重复次数

超算状态：已准备并推送情绪×目的三组脚本；未收到GPU成功运行结果。该包不是在线存储巩固或DeepSeek分支的完整端到端包，后续须分别部署和记录。

附录｜汇报口径与材料来源

可直接使用的约两分钟汇报稿

我最近围绕心理学启发的长期记忆系统做了三类探索：情绪能否成为额外提取线索，主动提取练习能否改善记忆，以及历史使用能否指导有限预算下的保留。

在情绪方向，我比较了词法、语义、混合检索和多种情绪融合。已有结果没有显示稳定的整体收益，但在少事件关键词的诊断题中，情绪有时能改善排序或补回证据。一个明显问题是，找到感受描述时可能丢掉事件背景，所以需要检验两者的联合召回。

在提取练习方向，我既做了保留机制模拟，也做了真实模型的练习与重读对照。分享记录中的DeepSeek实验完成16次练习和30道测试，原始自动评分为不更新15题、重读14题、练习16题，但时间题误判会影响这一差距，暂时不能作为有效性结论。

在保留方向，历史证据反馈在部分预算下有收益，但旧方法使用了标准答案证据，尚未证明可部署的实际使用反馈同样有效。此外，竞争抑制实验发现某些更新会伤害未来问题，说明保留收益与更新风险需要一起评估。

下一步我优先修复评价和反馈定义，用更强模型、同预算重读对照、LFU/LRU基线及新问题迁移，判断收益究竟来自主动提取、信息整理还是简单频次缓存。当前汇报定位是研究问题与初步验证，不是已经成立的新方法。

证据来源与交付说明

标记	来源与解释
工作区运行／核查	当前项目报告、逐查询输出、配置和日志；相关性多为AI暂定或官方证据代理
上传日志	WorkBuddy“全部实验脚本与原始输出.zip”；部分数据缓存缺失，未全量重跑
分享记录报告值	新增ChatGPT分享对话；DeepSeek/BGE分支未提供本轮可核验的完整运行产物
最新用户汇总	新污染、预测等数值尚未与对应新代码逐项匹配

新增分享来源：https://chatgpt.com/share/6ace1ec8-d014-83e8-ba02-4bf0f38e3333

主要内部依据：research_progress_summary_20261013.md；storage_direction_claim_audit.md；experiment_report.md；emotion_goal_method_prototype.md；rif_robustness_experiment.md；related_research_replication_audit.md。

范围说明：分享分支尚未运行LongMemEval，但当前项目其他分支已经运行，不能合并写成“整个项目未运行”。此前FLAN真实生成也已执行，因此“端到端完全未做”应改为“强模型确认性端到端验证尚未完成”。